

기상·공간정보 기반 전력설비 인근 산불위험 분석

1 분석 배경 및 목표

송·배전 설비는 산불을 일으키는 원인이자 동시에 피해 대상이다. 전력설비 발화가 전체 산불에서 차지하는 비중은 크지 않으나, 강풍과 중첩될 경우 대형 산불과 막대한 피해를 유발한다[1]. 역으로 산불은 전주와 전선을 손상시켜 전력망 운영에도 영향을 미치므로, 설비와 산불은 양방향 상호작용 관계에 있다[2]. 특히 강원도는 봄철 건조 기후와 강풍에 더해 태백산맥을 넘어 가속·건조되는 양간지풍이 중첩되는 지역으로, 이 상호작용이 구조적으로 강하게 나타난다. 2019년 고성 산불은 특고압 전선의 아크가 강풍을 타고 확산된 대표적 사례이다.

이러한 환경에서 운영 주체가 필요로 하는 것은 단순한 권역 단위 위험 등급이 아니라, 한정된 점검·보강 자원을 어디에 우선 배분할지를 판단할 수 있는 개별 전주 단위의 위험 변별이다. 그러나 전력설비 산불위험 분석은 위험 사례(발화)만 관측되고 비위험 사례는 관측되지 않는 양성-미표지(Positive-Unlabeled, PU) 문제에 해당하여, 통상적인 분류 학습을 그대로 적용하기 어렵다. 따라서 (i) PU 구조 아래에서 위험을 추정하면서, (ii) 동일 권역 내 전주 간 상대 위험을 구분하고, (iii) 소표본 조건에서도 예측 불확실성을 신뢰성 있게 정량화하는 접근이 요구된다.

기존 방법은 이러한 요구를 충분히 충족하지 못한다. PU 학습[3]과 출현 자료 기반 중분포모형(MaxEnt)[4]이 널리 활용되어 왔으나, 관측 표본 편향에 취약하고[5], 절대적 발생확률을 식별하기 어려우며, 평가가 주로 지점 수준 변별력에 머문다는 한계가 있다[6]. 비음수 위험추정 기반 딥 PU 학습(nnPU)[7]과 같은 딥러닝 접근은 복잡한 비선형 관계를 학습할 수 있으나, 다수의 매개변수를 안정적으로 추정하려면 충분한 양성 표본이 필요하다. 본 과제에서 검증 가능한 발화 앵커는 약 700건에 불과하여, 이러한 소표본 조건에서 딥러닝은 과적합 위험이 크고 불확실성을 신뢰성 있게 정량화하기 어렵다. 무엇보다 이들 방법은 공통적으로 동일 권역 내 개별 설비 간 위험 차이를 정량적으로 구분하는 데 제약이 있어, 앞서 제시한 세 요구 가운데 핵심인 전주 단위 변별을 충족하지 못한다.

본 연구는 강원권에 구축한 가상 전주 1,387,831본을 대상으로 위 요구를 직접 겨냥하여 산불위험을 추정한다. 위험은 설비 자체의 발화뿐 아니라 외부 산불이 전주로 번지는 피해 가능성까지 포함한다. 또한 권역 간 구분을 넘어 전주 단위 위험 변별(within-regime discrimination)을 수행하고, 베이지안 사후분포와 등각(conformal) 예측 기법으로 예측 불확실성을 함께 정량화한다.

2 분석 데이터 및 전처리

본 연구에서 사용된 데이터는 다음 표와 같다.

구분	데이터	용도
기상	일별 산불기상지수[미세연료 습도(FFMC), 하층건조지수(DMC), 심층건조지수(DC), 초기확산지수(ISI), 누적건조지수(BUI), 종합화재기상지수(FWI)], 양간지풍 일수	기상 위험 (W)
공간 데이터	지형(고도·경사·사면), 토지피복, 식생정보(NDVI·NBR·NDMI), 도로·송전선·변전소 거리	발화기하·연료·노출 (S)
발화이력	산림청 산불발생대장(FFAS, 강원) 발화점 좌표·발생시각	PU 양성(P)

첫째, 기상 데이터는 일별 산불기상지수와 풍속을 기반으로 산불조심기간(2-5월) 동안의 시론 통계(평균, 90분위수, 고위험일 비율)로 집계한 뒤, 각 전주를 최근접 관측소(거리 중앙값 4.8 km)에 매핑하였다. 기상 요인이 전주 단위가 아니라 약 13 km 규모의 공간에서 작용한다는 점을 고려하여, 공간 보간 대신 일별 관측값의 시론 집계와 최근접 관측소 기반 할당을 적용하였다. 둘째, 위경도 좌표는 강원권 기준의 평면 거리(km)로 변환하여 도로, 송전선, 변전소까지의 거리 및 풍하 확산 계산에 일관된 단위로 사용하였으며, 권역 배정에 사용되는 게이트 변수(경도, 고도, 양간지풍 일수)는 z-표준화하였다.


셋째, 발화 지점은 반경 1 km 이내의 전주에 귀속하되, 발화 라벨은 학습 대상이 아니라 검증 및 임계값 설정을 위한 기준으로만 사용하여 정보 누수를 방지하였다. 넷째, 공간 자기상관으로 인한 평가 편향을 완화하기 위해 10 km 단위의 공간 블록 교차검증 폴드를 구성하였다. 다섯째, 산림청 산불발생대장(FFAS) 좌표는 지번 중심점 기반이므로 점이 아닌 면으로 취급하였으며, 결측 및 시기 편향이 존재하는 원인·피해 관련 변수는 제외하였다. 식생 정보 등 소수 결측 변수는 전역 중앙값으로 대체하고, 전주 단위 데이터의 정합성을 검증하였다.

탐색적 자료분석에서는 전주 및 발화점 분포, 발화 원인, 기상 커버리지에 대한 기초 분석과 위험 분해·체제 분포·공간 자기상관 분석을 수행하여 데이터의 구조적 특성을 확인하였다.


분포 측면에서 발화점의 91%가 산림에 위치하는 반면, 전주는 농업(37.0%), 초지(21.3%), 산림(17.9%), 시가화(17.3%) 등 다양한 토지피복에 걸쳐 분포한다. 이는 산림 여부만으로 전주 위험을 설명하기 어렵고, 산림 인접성뿐 아니라 토지피복, 연료 조건, 도로 및 송전선 접근성을 함께 고려할 필요가 있음을 보여준다. 한편 발화 원인은 입산자 실화(34%), 쓰레기 소각(18%) 등 인적 요인이 대부분을 차지하며, 전기·설비 관련 발화는 27건(3%)에 불과하여 전주 위험이 특정 설비 요인에 국한되지 않음을 보여준다.

위험을 지배하는 요인은 권역별로 뚜렷이 상이한 경향이 관측된다(그림 2). 영동권은 양간지풍 발생 일수와 산불기상지수(FWI)가 함께 높아 기상 요인이 우세하고, 회랑 지역은 송전선 인근의 풍하 노출이, 영서·산간 지역은 인적 발화에 따른 발화 성향이 각각 두드러진다. 즉 발화를 이끄는 핵심 변수의 분포 자체가 권역마다 구분된다. 한편 화재 당일 풍속(상관계수 0.29)과

초기 확산지수(0.26, n=135)는 화재 규모와 유의한 양의 상관을 보여, 화재 규모가 발화 지점의 지형 요인보다 바람 조건과 초기 확산 환경에 의해 더 크게 좌우됨을 확인하였다.




<그림 1. 시군별 발화점 및 발화원인>




<그림 2. 체제별 핵심 파생변수 분포>

기상 자료의 대표성 측면에서 강원 지역에는 109개 기상 관측 지점(방재기상관측소 94개, 종관기상관측소 15개)이 존재하며, 전주에서 최근접 관측소까지의 거리는 중앙값 4.8 km, 10 km 초과 비율은 7.7%로 나타나 전주 단위 시론 기상 추정에 충분한 공간 밀도를 확보하고 있다.(그림3) 또한 산불조심기간(2~5월)에는 초기 확산지수 및 미세연료 습도가 비시즌 대비 고위험 영역으로 이동하며, 고위험 임계값(초기 확산지수 10, 미세연료 습도 90)이 관측소 기반 일별 분포의 90분위수(각각 9.79, 91.5)와 대체로 정합하여 지표의 경험적 타당성을 뒷받침한다.(그림3)




<그림3. 기상관측소 영향권과 전주 커버리지>



<그림4. 산불조심기간에따른 ISI 및 FFMC 분포>

3 분석방법

전주 P의 위험을 $R(p)=I(p) \cdot S(p) \cdot W(p)$ 로 분해한다. I는 발화 성향, S는 정적 취약도와 풍하 노출, W는 기상 및 계절 인자이며, 세 항이 동시에 증가할 때 위험이 극대화된다. 강원 전역에 적합한 결과, 전체 분산에 대한 기여는 발화 성향 0.52, 기상 0.40, 풍하 노출 0.08로 나타났다(그림 5). 다만 앞서 2장에서 확인한 바와 같이 발화를 지배하는 요인은 권역마다 상이하므로(그림 2), 단일 모형으로 강원 전역의 발화 기작을 포괄하기 어렵다. 이는 권역별 전문가(expert)를 두는 혼합전문가(MoE) 구조의 직접적 근거가 된다.




<그림 5. 위험 분해 $R = I * S * W$ 의 분산기여>

(1) 발화 성향 - 지역 혼합전문가(MoE) 권역별 발화 구동인자(표 1)에 따라 권역마다 전문가(expert)를 두고, 전주 위치에 따라 가중을 부여하는 혼합전문가 구조를 적용한다.[8] 태백산맥을 기준으로 영동·영서를 구분하고 양간지풍 집중 구간을 회랑(양양-고성), 고지대를 산악으로 세분하여 총 4개 레짐을 구성하며(그림 6), 게이트 축(경도, 고도, 양간일수)이 이 분할과 대응하므로 전주는 위치만으로 자기 레짐에 연속 배정된다. 각 전문가는 공통 피쳐(산림거리·도로·송전선거리·FWI·양간일수·연료가연성·토지피복)를 레짐 고유 가중으로 결합한 발화 규칙이며, 게이트는 위치 피쳐인 경도, 고도, 양간일수와 레짐 중심 μ_r 의 거리를 softmax로 변환해 가중(합=1)을 산출하되 위험 피쳐는 전문가S항에 귀속시킨다. 경계 전주는 인접 전문가에 분산 배정되어 하드 분할의 MAUP을 완화한다(표 1, 그36). 이때 게이트 가중치 $g_r(p)$ 는 위치 피쳐와 레짐 중간간 거리로 계산하며 발화성향 $I(p)$ 는 각 전문가의 출력을 해당 가중치로 결합하여 계산한다.

$$g_r(p) = \frac{\exp(-\|z_p - \mu_r\|^2/\tau)}{\sum \exp(-\|z_p - \mu_r\|^2/\tau)}, \quad I(p) = \sum_r g_r(p) \sum_j w_{rj} f_j(p)$$


레짐	대표 지역	발화 구동 인자	지배 위험 항
영동	강릉·동해·삼척	가뭄·FWI	기상W
회랑	양양·고성·속초	양간지풍·송전선	풍하노출 S
영서	내륙	인적 발화 (소각·입산)	발화성향 I
산악	고지	연료·도로 접근	발화성향 I

표 1. 레짐별 발화 구동인자 및 지배 위험항



< 그림6. 강원 지역4개 공간 분할>

(2) 풍하노출 S 양간지풍 확산 모형 : 서풍 계열의 양간지풍(prior $\approx 270^\circ$) 조건에서 발화원의 풍하 확산을 몬테카를로 시뮬레이션으로 모사하여 전주별 도달 확률 $P_{\text{exp}}(p) = \frac{1}{S} [p \text{가풍하커널에도달}]$ 을 산출하고 최종 풍하노출 지표 $S(p) = (1-a_p)S_0(p) + a_p P_{\text{exp}}(p)$ 처는 정적 취약도 $S_0(p)$ 풍하도달확률 $P_{\text{exp}}(p)$ 를 조건부 강도 a_p (영동, 회랑 여부와 양간지풍 강도에 의해 결정)의 가중치로 선형 결합하여 계산한다.



<그림7. 양간지풍 풍하 노출량 - (좌) 포화 노출(변별 없음) vs (우) 발화가중 v2(풍하 동측 변별)>

3) 기상 인자 W : 기상 인자 W : 기존 기상 변수에 발화 당일의 기상 상태를 반영하기 위해 FWI 구성 요소(FFMC, DMC, DC, ISI, BUI, 종합 FWI)를 후보로 두고, 각 요소가 발화 발생 및 초기 확산에 대해 갖는 설명력을 기준으로 변수를 선별하였다. 선별 결과 최종 채택된 구성 요소는 4장에 제시한다.

(4) 지역을 보정·불확실성. 격자별 발화 건수 (y)와 노출량(전주 수, E)에 대해 인접 격자의 정보를 공유하는 공간 BYM2 사후 [9](Poisson-CAR, INLA식 Laplace 근사[10])를 둔다. 발화가 관측되지 않은 격자도 이웃에서 강도를 빌려 공간 자기상관이 매끄러워지며(Moran's I 0.098→0.112), 이를 물리 base risk에 MC 전파해 전주별 90% 신뢰구간 $[r_{lo}, r_{hi}]$ 를 산출한다. 단, 0/1 결정에는 쓰지 않고 운영 보조 산출물로만 쓴다.[11]


(5) 권역 기반 학습·결정 학습과 의사결정 모두 권역 내(within-regime) 변별력을 기준으로 수행하였다. 가중치는 권역별 within-recall의 동일가중 평균을 최대화하도록 조정하였으며, 최종 컷오프는 권역별 발화 앵커 밀도에 비례한 양성 예산을 각 권역 내 위험 순위에 따라 배분하여 결정하였다.

4 결과 및 검증

목적함수를 전역 AUC 중심에서 레짐 내 변별 기준으로 전환한 결과, 전역 성능(AUC 0.63)은 유지되면서 동일 레짐 내 AUC가 0.488에서 0.560으로 상승하여 레짐 내 위험도 순위가 개선되었다. 이는 기존 모델이 지역 간 위험도 차이는 효과적으로 학습하였으나, 동일 지역 내 전주의 상대적 위험도는 충분히 구분하지 못하였음을 시사한다. 다만 top-5% recall은 0.097에서 0.071로 감소하여, 극단적 고위험 사례에 대한 집중도는 일부 완화되었다.

이를 기반으로 시군별 전주 위험지도를 작성한 결과(그림 8), 16개 시군 모두에서 전주 단위의 연속적인 위험 그라데이션이 형성되었다. 시군 간 평균 위험도는 영동·회랑·산악에서 70-85점, 영서 내륙에서 9-40점 수준으로 유지되어 레짐 간 구조적 대비를 반영하였으며, 각 시군 내부에서도 전주별 위험도가 연속적으로 분포하여 레짐 내 변별력이 확보되었다. 이에 따라 전역 단일 순위에서는 후순위로 밀리던 영서·산악 지역에서도 시군 내 고위험 전주를 식별할 수 있어, 강원 전역 단위의 운영이 가능해졌다.


또한 학습 기간에 발화 이력이 없는 시군에서도 물리·기상·풍하 정보를 기반으로 위험도가 차등 부여되었다. 예를 들어 태백(전주 2.8만 기)은 평균 위험도 73으로 고위험, 화천은 9.8로 저위험으로 평가되어, 발화 이력이 없는 지역에서도 연료·지형·기상 특성을 반영한 위험도 산정이 가능함을 확인하였다.




<그림8 시군별 전주 위험지도>

변수 선별 결과, FPMC와 ISI는 각각 발화 발생과 초기 확산을 안정적으로 설명한 반면 DMC, DC, BUI 및 종합 FWI는 추가 설명력이 제한적이었다. 이에 따라 최종 모형의 기상 인자(W)는 FPMC와 ISI로 구성하였다. 이렇게 구성된 기상 신호는 레짐별로 다르게 나타났다. 영동(FWI 0.725, ISI 0.698)과 회랑(풍속 0.664)에서는 발화일과 비발화일이 명확히 구분된 반면, 영서에서는 풍속 기반 AUC가 0.51로 유의한 변별력을 보이지 않았다. 또한 영서의 주말 발화 비중은 영동 대비 약 2배로 높아 인적 요인의 영향이 상대적으로 큰 것으로 나타났다. 이러한 차이는 레짐별 발화 메커니즘이 상이함을 시사하며, 레짐별 피처를 차등 적용한 설계의 근거를 제공한다.

확산검증결과 풍하 방향 추정은 실제 확산 패턴과 정합하였다. 2019년 고성-속초 산불에서는 동측 약 6.7 km 확산이 관측되었으며, 이는 모델의 east_frac = 0.99 추정과 일치한다. 해당 사건에서 발화점 반경 5 km 내 전주의 평균 위험은 0.90 percentile 수준이었고, top-10% 집중도는 64.6%로 고위험 지역을 효과적으로 포착하였다(그림 9). 또한 10 km 공간 블록 교차검증에서 발화점 recall은 상위 1-5% 구간에서 랜덤 기준선 대비 약 1.5-1.8배 높게 나타났으며, 운영점인 상위 2%에서는 약 1.6배의 향상을 보였다(그림 10). 체제별 컷(regime-anchor)은 전역 단일 컷보다 평균 recall이 소폭 높아(0.0619 vs. 0.0611) 최종 운영 전략으로 채택하였다. 또한 상위 5% 기준에서 무작위 분할과 공간 분할의 recall은 각각 0.070과 0.077로 차이가 -0.006에 그쳐 공간 자기상관에 따른 성능 과대평가는 관찰되지 않았다. 운영 양성 비율은 한국전력의 현장 점검 가용 용량을 고려하여 2%로 설정하였으며, 해당 구간에서 F1과 recall이 안정적으로 유지되었다. 다만 발화점은 매핑 기준 706건으로 희소하고 인적 발화가 대부분을 차지하므로 recall의 절대값보다는 전주 간 상대적 위험도를 우선순위화하는 랭킹 지표로 해석하는 것이 적절하다.



<그림 9 양간지풍 풍하 방향을 고려한 2019년 고성-속초 산불 사례 검증>




<그림 10 공간 블록 교차검증 기반 발화점 recall@top-k>

송전선 거리는 점추정에서 약한 양(+)의 효과를 보였으나 부트스트랩 신뢰구간이 0을 포함하여 단독으로는 유의하지 않았으며, 변전소 거리는 오히려 성능을 저하시켰다. 이는 송전선에 가까울수록 위험이 높다는 단순 근접 규칙이 성립하지 않음을 의미하며, 전주 인근 위험이 권역별 발화기제와 기상, 풍하 확산의 결합으로 결정됨을, 곧 I-S-W 구조가 필요함을 뒷받침한다. 그럼에도 모델은 희소한 설비발화(27건)를 인적발화 이상으로 포착하였다(recall 0.167 대 0.151).


발화 원인별 비교에서는 설비 발화 사례가 약 18건으로 희소하고 별도의 학습-평가 분할 없이 수행되었으므로 절대 성능이 아닌 상대 비교로 해석하였다. 설비 발화의 recall@top10%는 0.167로 인적 발화(human, 0.151)와 동등하거나 다소 높은 수준을 보여, 모델이 설비 발화를 최소한 인적 발화 수준 이상으로 포착함을 확인하였다. 또한 2019년 고성 산불은 FFAS 원인 필드에 '특고압 전선 아크 불티'로 기록된 설비 발화 사례이며, 최근접 가상 전주(0.32 km)에 매핑되었다.

불확실성 추정은 conformal prediction과 Bayesian credible interval로 검증하였다. 홀드아웃 발화점을 기준으로 평가한 결과, 레짐별 conformal prediction의 실측 커버리지는 0.89로 명목 90% 수준에 근접하였으며, Bayesian credible interval은 1.00으로 보다 보수적인 특성을 보였다(그림 11). 모든 fold에서 임계값과 사후분포는 학습 데이터만을 이용해 추정하여 test 정보 누수를 방지하였다.




<그림 11. 체제별 예측구간 커버리지>

이를 기반으로 검증 데이터셋에 모델을 적용해본 결과 전체중 27,757본이 고위험으로 판정되었으며, 권역별 배분은 영동 3,827본, 회랑 2,417본, 영서 15,712본, 산악 5,801본이다.(그림12) 권역별 발화영커밀도에 비례해 양성 예상을 배분함으로써 발화가 잦은 영동으로의 편중을 완화하였고, 전역 단일 임계에서는 후순위로 밀리던 영서·산악의 권역 내 고위험 전주까지 포함하였다. 고위험 전주의 공간 분포와 권역별 구성은 그림 13에 제시하였다. 마찬가지로 의사결정에 대한 신뢰도를 높이기 위해 그림 14과 같이 사후 신뢰구간을 계산하여 추정의 불확실성을 반영하였고 위험도는 높으나 불확실성이 높으나 발화 이력이 희소하거나 표본이 적은 권역은 추가 관측과 현장확인을 통해 판단한다.



<그림 12. 테스트셋에 대한 강원전주 산불 위험지도>



<그림 13. 검증데이터셋 대한 위험분포>

<그림 14. 검증데이터셋의 위험 및 사후 불확실성>

5 활용방안

본 모델은 한정된 점검·보강 자원의 전주 단위 우선 배분을 가능하게 한다. 권역별 발화 기제를 반영함으로써, 전역 단일 기준에서 후순위에 놓이던 영서·산악의 고위험 전주까지 포괄하여 강원 전역 단위의 운영을 지원한다. 자원 배분은 발화 기제에 따라 차등화된다. 영동·회랑은 양간지풍·FWI 경보일에 맞춘 양양-고성 회랑 송전선의 집중 감시 대상이며, 영서는 주말·소각철 등 인적 요인 취약 구간의 상시 순찰 대상, 산악은 도로변 접근 발화 가능 구간의 관리 대상이다. 의사결정 단계에서는 점추정 위험도와 사후 신뢰구간이 함께 제공된다. 위험도가 높고 불확실성이 낮은 전주는 즉시 점검·보강 대상으로 분류되며, 위험도가 높으나 불확실성이 큰 전주, 곧 발화 이력이 희소하거나 표본이 적은 권역의 전주는 추가 관측과 현장 확인을 통해 판단된다. 정적 우선순위는 운영의 기본 골격에 해당하며, 일별 FWI·양간지풍 예보와의 연동을 통해 계절 단위의 정적 위험도가 일 단위 동적 경보 체계로 확장된다.

<참고문헌>

- [1] Syphard, A. D., & Keeley, J. E. (2015). Location, timing and extent of wildfire vary by cause of ignition. *International Journal of Wildland Fire*, 24(1), 37-47. <https://doi.org/10.1071/WF14024>
- [2] Jazebi, S., de León, F., & Nelson, A. (2020). Review of Wildfire Management Techniques-Part I: Causes, Prevention, Detection, Suppression, and Data Analytics. *IEEE Transactions on Power Delivery*, 35(1), 430-439.
- [3] Bekker, J., & Davis, J. (2020). Learning from positive and unlabeled data: A survey. *Machine Learning*, 109(4), 719-760.
- [4] Phillips, S. J., Anderson, R. P., & Schapire, R. E. (2006). Maximum entropy modeling of species geographic distributions. *Ecological Modelling*, 190(3-4), 231-259.
- [5] Phillips, S. J., Dudík, M., Elith, J., Graham, C. H., Lehmann, A., Leathwick, J., & Ferrier, S. (2009). Sample selection bias and presence-only distribution models. *Ecological Applications*, 19(1), 181-197.
- [6] Phillips, S. J., & Elith, J. (2010). POC plots: calibrating species distribution models with presence-only data. *Ecology*, 91(8), 2476-2484.
- [7] Kiryo, R., Niu, G., du Plessis, M. C., & Sugiyama, M. (2017). Positive-unlabeled learning with non-negative risk estimator. *NeurIPS*, 30.
- [8] Jacobs, R. A., Jordan, M. I., Nowlan, S. J., & Hinton, G. E. (1991). Adaptive mixtures of local experts. *Neural Computation*, 3(1), 79-87.
- [9] Riebler, A., Sørbye, S. H., Simpson, D., & Rue, H. (2016). An intuitive Bayesian spatial model for disease mapping that accounts for scaling. *Statistical Methods in Medical Research*, 25(4), 1145-1165.
- [10] Rue, H., Martino, S., & Chopin, N. (2009). Approximate Bayesian inference for latent Gaussian models by using integrated nested Laplace approximations. *Journal of the Royal Statistical Society: Series B*, 71(2), 319-392.
- [11] Vovk, V., Gammerman, A., & Shafer, G. (2005). *Algorithmic Learning in a Random World*. Springer.